

Modelagem flexível de fenômenos físicos com a distribuição lambda generalizada: uma abordagem computacional didática com o pyGLAM

Renata Maria Pensin¹, Victor Hugo Moreira do Couto Souza¹, Wanderlei Malaquias Pereira Junior^{1,*}, Marcos Luiz Henrique²

¹Universidade Federal de Catalão (UFCAT), Catalão, 75701-180, Goiás, Brasil

²Núcleo Interdisciplinar de Ciências Exatas e da Natureza (NICEN/CAA), Universidade Federal de Pernambuco (UFPE), Caruaru, 55014-900, Pernambuco, Brasil

*Autor correspondente: wanderlei_junior@ufcat.edu.br

Resumo

A distribuição normal costuma ser a única referência apresentada aos estudantes para descrever a variabilidade de grandezas físicas, embora muitas delas sejam assimétricas ou limitadas. Este artigo apresenta uma abordagem didática para a modelagem probabilística de dados físicos reais com a distribuição lambda generalizada, na parametrização FKML, definida por uma função quantil explícita. Explica-se o significado dos quatro parâmetros, as condições de validade e de suporte e o ajuste pelo método dos momentos, implementado na biblioteca Python `pyglam`. O procedimento é aplicado a dois conjuntos de dados de uma estação meteorológica automática do INMET em Brasília, que são a velocidade média diária do vento, comparada às distribuições de Rayleigh e de Weibull, e a temperatura média diária de julho, comparada à distribuição normal. A avaliação usa a distância de Kolmogorov-Smirnov e os desvios de quantis nas unidades da grandeza. No vento, a distribuição flexível reduz os desvios de quantis a menos da resolução das medições, mas seu suporte exclui os dias de vento mais fraco; na temperatura, a normal já descreve os dados dentro da incerteza instrumental. Os exemplos mostram que um bom ajuste exige examinar o suporte e a aderência, e não apenas os momentos, e que a escolha do modelo depende da pergunta física. Todos os resultados são reproduzidos por um notebook disponibilizado com o artigo.

Palavras-chave: distribuição lambda generalizada; função quantil; método dos momentos; dados meteorológicos; ensino de estatística; Python.

Abstract

Flexible modelling of physical phenomena with the generalized lambda distribution: a didactic computational approach with pyGLAM. The normal distribution is often the only reference students are given to describe the variability of physical quantities, although many of them are skewed or bounded. This paper presents a didactic approach to the probabilistic modelling of real physical data with the generalized lambda distribution, in the FKML parameterization, defined by an explicit quantile function. It explains the meaning of the four parameters, the conditions of validity and support, and the fit by the method of moments,

implemented in the Python library `pyglam`. The procedure is applied to two data sets from an automatic weather station of INMET in Brasília, Brazil, namely the daily mean wind speed, compared with the Rayleigh and Weibull distributions, and the daily mean temperature in July, compared with the normal distribution. The assessment uses the Kolmogorov-Smirnov distance and quantile deviations in the units of the quantity. For the wind, the flexible distribution reduces the quantile deviations below the resolution of the measurements, but its support excludes the calmest days; for the temperature, the normal distribution already describes the data within the instrumental uncertainty. The examples show that a good fit requires examining the support and the goodness of fit, not only the moments, and that the choice of model depends on the physical question. All results are reproduced by a notebook provided with the paper.

Keywords: generalized lambda distribution; quantile function; method of moments; meteorological data; statistics education; Python.

1. Introdução

1.1 Distribuições no ensino de física e engenharia

A descrição matemática da variabilidade de medições e grandezas observáveis é um pilar fundamental no ensino e na prática da física e da engenharia. Fatores estocásticos e incertezas estão presentes em todas as escalas da observação empírica. Frequentemente, a estatística introdutória ensinada nos cursos de graduação concentra-se em medidas de tendência central, como a média. Contudo, a média isolada é insuficiente para capturar a dispersão, a assimetria, os quantis de interesse para projetos ou a frequência de ocorrência de valores extremos e anômalos.

Grandezas físicas reais apresentam comportamentos variados e complexos. Ao analisar a velocidade do vento em estudos de escoamento, as variações de temperatura em termodinâmica, o tempo de falha de componentes mecânicos, ou a propagação da profundidade de carbonatação em estruturas de concreto, observa-se que a variabilidade não é uniforme. Nessas grandezas, a dispersão estatística observada nos dados pode refletir a flutuação física intrínseca do próprio fenômeno, o erro instrumental associado aos equipamentos de medição, ou a incerteza epistêmica sobre os parâmetros de um modelo. Muitas vezes, uma única distribuição de probabilidade ajustada a dados experimentais reflete a superposição simultânea dessas múltiplas fontes de variabilidade.

Historicamente e por conveniência didática, a distribuição normal (ou gaussiana) é apresentada como a referência primária e, por vezes, exclusiva. No entanto, é fundamental questionar aos estudantes em quais situações práticas a simetria estrita e o suporte infinito $(-\infty, \infty)$ da distribuição normal são fisicamente adequados. Um foco exclusivo na normalidade pode levar estudantes a forçarem dados manifestamente assimétricos ou

de cauda pesada em modelos simétricos, deixando de lado ferramentas mais ricas para o tratamento de incertezas e a análise de falhas.

1.2 Percurso histórico das distribuições particulares às famílias flexíveis

O esforço analítico para representar distribuições de dados que escapam à normalidade impulsionou, ao longo de mais de um século, o desenvolvimento de famílias de distribuições de probabilidade. Em vez de delinear uma cronologia exaustiva, é mais instrutivo observar esta evolução pelos problemas matemáticos que cada geração de pesquisadores tentou superar.

O marco inicial dessa trajetória pode ser atribuído a Pearson (1895), que identificou a limitação das curvas gaussianas para fenômenos biológicos e físicos assimétricos. Pearson desenvolveu um sistema de curvas contínuas baseadas na solução de uma equação diferencial comum, ampliando o repertório analítico disponível muito além da distribuição normal e abrindo caminho para a modelagem sistemática da assimetria.

Cinquenta anos depois, Johnson (1949) abordou o problema por outro ângulo, propondo a construção de sistemas de distribuições através de transformações não lineares da variável normal padrão. Este sistema permitiu uma flexibilidade notável, cobrindo uma vasta região do plano formado pela assimetria e pela curtose.

Uma mudança de paradigma ocorreu com a família lambda (Hastings et al., 1947), difundida por John Tukey (Tukey, 1960). Em lugar de trabalhar diretamente com a função densidade de probabilidade (FDP), a família é definida pela função quantil (a função inversa da função distribuição acumulada), que controla a forma da distribuição. Esta abordagem facilitou enormemente o tratamento computacional e matemático dos dados e das caudas.

Com base na facilidade da função quantil, Ramberg e Schmeiser (1974) generalizaram a família lambda, motivados pelo problema prático de criar um método aproximado e computacionalmente eficiente para gerar variáveis aleatórias assimétricas em simulações de Monte Carlo. O refinamento dessa generalização culminou na formulação de Freimer et al. (1988), que estabeleceu a parametrização adotada no presente artigo, conhecida pelas iniciais dos autores como GLD-FKML (do inglês *Generalized Lambda Distribution*, na parametrização de Freimer, Kollia, Mudholkar e Lin).

Esse percurso histórico converge para uma pergunta eminentemente prática na modelagem de dados físicos, a de como representar diferentes formas, assimetrias e pesos de cauda com uma mesma expressão matemática de função quantil. A família GLD oferece uma resposta a esta pergunta, embora não deva ser encarada como uma panaceia universal, tampouco assumida como uma generalização em que toda distribuição clássica se encaixa como caso particular exato.

1.3 Por que utilizar distribuições flexíveis?

A vantagem de adotar distribuições flexíveis como a GLD reside na capacidade de representar uma grande variedade de comportamentos estocásticos sob um procedimento algorítmico e computacional comum. Isso reduz a necessidade de testar muitas famílias de distribuições distintas para encontrar um ajuste empírico adequado a um conjunto de dados.

Entretanto, esse poder representativo tem um custo analítico que deve ser explicitado em sala de aula. Modelos com quatro parâmetros, como a GLD-FKML, exigem uma estimação mais delicada, são suscetíveis a instabilidades na presença de amostras pequenas, e exigem verificação cuidadosa para garantir que o suporte matemático da distribuição não viole o suporte físico da grandeza (por exemplo, atribuindo probabilidade a valores negativos de variáveis estritamente positivas).

Ao longo dos exemplos práticos deste artigo, três questões fundamentais guiarão a avaliação das distribuições, que são a *proximidade dos dados* (quão bem o modelo se ajusta às observações empíricas), a *simplicidade do modelo* (o princípio da parcimônia) e a *plausibilidade física* (se as caudas e os limites extrapolados pelo modelo fazem sentido para o fenômeno). Nenhuma destas questões é plenamente resolvida apenas pela contagem de parâmetros, tampouco pela simples inspeção visual de um histograma (NIST/SEMATECH, 2012).

1.4 Aplicações contemporâneas e ferramentas computacionais

Se no passado o uso da GLD era limitado pelo custo computacional da estimação de parâmetros, hoje essas distribuições encontram aplicações de fronteira na engenharia e nas ciências computacionais. Elas são utilizadas na representação de distribuições de saída de simuladores estocásticos e na quantificação de incertezas. Trabalhos contemporâneos, como o de Zhu e Sudret (2021), empregam regressões baseadas na GLD para criar metamodelos de engenharia. Desenvolvimentos mais recentes, como o modelo MF-GLaM (Giannoukou et al., 2025), expandem essa fronteira permitindo a integração de simulações com múltiplos níveis de fidelidade.

Para transpor esses conceitos para a prática didática, faz-se uso de um ecossistema computacional acessível. A Tabela 1 resume as principais ferramentas disponíveis para o trabalho com a GLD.

1.5 Objetivo, contribuição didática e organização

O objetivo central do presente artigo é apresentar uma via didática para o ensino de distribuições de probabilidade flexíveis, estruturada sobre a análise de dados físicos reais.

A contribuição deste trabalho reside em instrumentar estudantes e educadores para além da aplicação mecânica de fórmulas. Ao final do percurso proposto, o leitor deverá ser capaz de interpretar a matemática por trás de uma função quantil, compreender os

Tabela 1: Ferramentas computacionais para ajuste e análise de distribuições flexíveis.

Ambiente	Ferramenta	Papel e aplicabilidade
Python	<code>pyglam</code> (Pereira Junior et al., 2026)	Biblioteca que implementa a GLD-FKML utilizada na execução dos exemplos práticos deste artigo.
Python	<code>scipy.stats</code> (Virtanen et al., 2020)	Contém distribuições e funções estatísticas clássicas; a distribuição <code>tukeylambda</code> abrange apenas a família original simétrica, não substituindo a FKML completa de quatro parâmetros.
R	<code>gld</code> (King et al., 2025)	Pacote tradicional na comunidade científica, que implementa diversas parametrizações e métodos de ajuste para a família <code>lambda</code> generalizada.
MATLAB	<code>fitdist</code>	Ferramenta de ajuste de distribuições do software; a GLD-FKML não consta entre as distribuições disponíveis, e seu uso requer rotinas próprias.

mecanismos e sensibilidades do ajuste por momentos, avaliar criticamente as distribuições ajustadas e, sobretudo, reconhecer os limites da interpretação física das caudas dessas distribuições.

O artigo está organizado da seguinte forma. A Seção 2 apresenta a função quantil, a parametrização FKML e o ajuste pelo método dos momentos. A Seção 3 discute o que significa modelar uma grandeza física por uma distribuição e estabelece o protocolo comum aos estudos de caso, desenvolvidos para a velocidade do vento na Seção 4 e para a temperatura na Seção 5. A Seção 6 reúne as considerações finais e indica os materiais computacionais que acompanham o artigo.

2. A distribuição `lambda` generalizada

2.1 Da densidade à função quantil

Uma variável aleatória contínua X costuma ser apresentada aos estudantes pela sua função distribuição acumulada (FDA),

$$F(x) = P(X \leq x), \quad (1)$$

e pela sua função densidade de probabilidade (FDP), $f(x) = F'(x)$, cuja integral em um intervalo fornece a probabilidade de observar um valor nele, $P(a < X \leq b) = \int_a^b f(x) dx$. Uma terceira descrição, equivalente e menos explorada no ensino, é a função quantil,

$$Q(u) = F^{-1}(u), \quad 0 < u < 1, \quad (2)$$

que responde à pergunta inversa, isto é, qual é o valor x abaixo do qual se encontra uma fração u das observações. Quando F não é estritamente crescente, $Q(u)$ é definida como

o menor x tal que $F(x) \geq u$. A leitura é direta e se faz nas unidades da grandeza, pois $Q(0,5)$ é a mediana e $Q(0,95)$ é o valor superado em apenas 5% das ocorrências.

Para uma distribuição contínua e estritamente crescente no seu suporte, vale $F(Q(u)) = u$. Derivando os dois lados em relação a u , obtém-se $f(Q(u)) Q'(u) = 1$, isto é,

$$f(Q(u)) = \frac{1}{Q'(u)}, \quad (3)$$

de modo que a densidade pode ser desenhada parametricamente, como o par $(Q(u), 1/Q'(u))$, sem que seja preciso inverter a função quantil.

Uma expressão explícita para Q tem uma segunda vantagem, que é a facilidade de gerar amostras. Se U é uniforme em $(0,1)$, então $X = Q(U)$ tem distribuição F , pois $P(Q(U) \leq x) = P(U \leq F(x)) = F(x)$. Esse é o método da transformação inversa. Nos estudos de caso deste artigo, porém, o ponto de partida são sempre dados observados.

O Código ?? mostra essas duas operações com a biblioteca `pyglam` (Pereira Junior et al., 2026), usada ao longo do artigo. A função quantil é avaliada pelo método `ppf`, e a amostragem pela transformação inversa, pelo método `rvs`.

Código 1: Quantis e amostragem de uma GLD-FKML com a biblioteca `pyglam`.

```
1 import numpy as np
2 from pyglam import GlamFKML
3
4 # GLD-FKML com lambda = (0; 1; 0,14; 0,14), forma próxima da normal
5 modelo = GlamFKML(0.0, 1.0, 0.14, 0.14)
6
7 # quantis lidos diretamente da função quantil Q(u)
8 mediana, p95 = modelo.ppf([0.50, 0.95])
9
10 # amostragem pela transformação inversa, X = Q(U)
11 amostra = modelo.rvs(size=1000, random_state=42)
```

2.2 A formulação FKML e o significado dos parâmetros

A distribuição lambda generalizada, na parametrização de Freimer et al. (1988), é definida pela função quantil

$$Q(u) = \lambda_1 + \frac{1}{\lambda_2} \left[\frac{u^{\lambda_3} - 1}{\lambda_3} - \frac{(1-u)^{\lambda_4} - 1}{\lambda_4} \right], \quad 0 < u < 1, \quad \lambda_2 > 0, \quad (4)$$

em que, para $\lambda_3 = 0$ ou $\lambda_4 = 0$, cada fração é substituída pelo seu limite, $\lim_{a \rightarrow 0} (u^a - 1)/a = \ln u$.

O papel de cada parâmetro está resumido na Tabela 2 e ilustrado na Figura 1, em que um parâmetro varia por vez e os demais ficam fixos. O parâmetro λ_1 desloca a distribuição sem alterar sua forma; λ_2 controla inversamente a escala, de modo que dobrá-lo reduz a dispersão pela metade; λ_3 e λ_4 controlam a forma, atuando principalmente sobre o lado

esquerdo e o lado direito da distribuição, respectivamente. Valores negativos tornam a cauda correspondente mais pesada e ilimitada, e valores positivos a tornam limitada. Se X tem unidade física, λ_1 tem essa unidade, λ_2 tem a unidade inversa e os parâmetros de forma são adimensionais.

Tabela 2: Interpretação didática dos parâmetros da GLD-FKML.

Parâmetro	Interpretação	Cuidado
λ_1	Desloca a distribuição	Não é, em geral, a média nem a mediana
λ_2	Controla inversamente a escala	Não é o desvio padrão; aumentá-lo, com os demais fixos, reduz a dispersão
λ_3, λ_4	Controlam conjuntamente a forma, com efeitos sobre os lados esquerdo e direito	Não identificar um deles exclusivamente com a assimetria e o outro com a curtose




Figura 1: Densidades da GLD-FKML variando um parâmetro por vez, a partir de $\boldsymbol{\lambda} = (0; 1; 0,14; 0,14)$, uma forma próxima da normal, com (a) o deslocamento por λ_1 , (b) a escala por λ_2 , (c) o lado esquerdo por λ_3 e (d) o lado direito por λ_4 .

2.3 Validade, suporte e momentos

Nem todo conjunto de parâmetros define uma distribuição, pois é preciso que a função quantil seja crescente. Derivando a Equação (4),

$$Q'(u) = \frac{u^{\lambda_3-1} + (1-u)^{\lambda_4-1}}{\lambda_2}, \quad (5)$$

cujos numeradores são positivos para quaisquer λ_3 e λ_4 reais. Na parametrização FKML, portanto, $\lambda_2 > 0$ basta para que a distribuição seja válida.

O suporte, isto é, o intervalo de valores possíveis, vai de $a = Q(0^+)$ a $b = Q(1^-)$, dados por

$$a = \begin{cases} \lambda_1 - \frac{1}{\lambda_2 \lambda_3}, & \lambda_3 > 0, \\ -\infty, & \lambda_3 \leq 0, \end{cases} \quad b = \begin{cases} \lambda_1 + \frac{1}{\lambda_2 \lambda_4}, & \lambda_4 > 0, \\ +\infty, & \lambda_4 \leq 0. \end{cases} \quad (6)$$

Aqui aparece a primeira ponte com a física. Uma distribuição matematicamente válida pode atribuir probabilidade a valores fisicamente impossíveis, como velocidades negativas, ou excluir valores que foram de fato observados. O suporte deve ser examinado depois de todo ajuste.

Validade e existência de momentos são propriedades distintas. O momento de ordem k existe quando $\lambda_3, \lambda_4 > -1/k$; o ajuste pelos quatro primeiros momentos exige, portanto, $\lambda_3, \lambda_4 > -1/4$.

2.4 O método dos momentos, passo a passo

A ideia do método dos momentos é escolher os parâmetros de modo que as características resumidas do modelo coincidam com as da amostra. Para observações $x_1, \dots, x_n$, definem-se

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i, \quad m_k = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^k, \quad \hat{\gamma}_1 = \frac{m_3}{m_2^{3/2}}, \quad \hat{\beta}_2 = \frac{m_4}{m_2^2}, \quad (7)$$

isto é, a média, a variância (com divisor n), a assimetria e a curtose. A curtose de Pearson, $\hat{\beta}_2$, vale 3 para a normal e mede o peso das observações afastadas do centro; ela não deve ser lida simplesmente como a altura do pico. O ajuste procura parâmetros $\boldsymbol{\lambda}$ que satisfaçam

$$\mu(\boldsymbol{\lambda}) = \bar{x}, \quad \sigma^2(\boldsymbol{\lambda}) = m_2, \quad \gamma_1(\boldsymbol{\lambda}) = \hat{\gamma}_1, \quad \beta_2(\boldsymbol{\lambda}) = \hat{\beta}_2. \quad (8)$$

Os momentos do modelo decorrem diretamente da função quantil. Como $X = Q(U)$, com U uniforme,

$$E[X^r] = \int_0^1 Q(u)^r du, \quad (9)$$

e, para a média, basta integrar a Equação (4) termo a termo, usando $\int_0^1 (u^\lambda - 1)/\lambda du = -1/(\lambda + 1)$, o que resulta em

$$E[X] = \lambda_1 + \frac{1}{\lambda_2} \left[\frac{1}{1 + \lambda_4} - \frac{1}{1 + \lambda_3} \right]. \quad (10)$$

Os momentos de ordem superior seguem o mesmo caminho e resultam em combinações de funções beta dos parâmetros de forma (Freimer et al., 1988); o notebook que acompanha o artigo os avalia numericamente.

O sistema da Equação (8) é não linear e é resolvido numericamente. O roteiro do

ajuste tem cinco passos.

1. calcular os quatro resumos amostrais da Equação (7);
2. propor parâmetros iniciais;
3. calcular os momentos do modelo e as discrepâncias em relação aos da amostra;
4. atualizar os parâmetros até que as discrepâncias se anulem;
5. verificar a validade, o domínio dos momentos, o suporte e a aderência aos dados.

Na biblioteca `pyglam` (Pereira Junior et al., 2026), a função `fit_lambdas` executa os passos 2 a 4 minimizando por mínimos quadrados os resíduos escalonados das quatro relações, a partir de vários pontos iniciais. Neste artigo, usaram-se 15 pontos, tomados de uma grade fixa que cobre formas limitadas, próximas da exponencial e de caudas pesadas. Cada candidato precisa definir uma distribuição válida e estar no domínio dos momentos; entre os válidos, escolhe-se o de menor resíduo. O último passo cabe ao usuário, e é nele que os estudos de caso se concentram.

2.5 O que o ajuste por momentos garante e o que precisa ser avaliado

Reproduzir os quatro momentos da amostra não identifica uma única distribuição, já que, mesmo dentro da família FKML, parâmetros diferentes podem ter os mesmos quatro momentos (King et al., 2025). Além disso, os momentos de ordem alta são sensíveis a poucos valores extremos, e o sucesso numérico do otimizador não informa se o modelo representa bem os dados. Por isso, conferir os momentos e avaliar a aderência são etapas complementares. Convém também distinguir a flexibilidade da família da capacidade de um estimador específico, pois um resultado desfavorável obtido pelo método dos momentos não demonstra que nenhuma GLD descreveria os dados.

3. Dados de grandezas físicas reais e modelagem por distribuições

3.1 O que significa dizer que uma grandeza segue uma distribuição?

Na física e na engenharia, afirmar que uma grandeza segue uma determinada distribuição de probabilidade significa estabelecer um modelo matemático descritivo para um conjunto de observações empíricas obtidas sob condições especificadas. A distribuição não é uma propriedade intrínseca da matéria ou do ambiente dissociada de como é medida; ela é

indissociável da definição da própria variável de interesse. Por exemplo, modelar a velocidade instantânea do vento em uma rajada exige um tratamento estatístico diferente daquele aplicado à velocidade média diária. Da mesma forma, as precipitações diárias em uma bacia hidrográfica apresentam um comportamento distinto dos máximos anuais de precipitação utilizados em projetos de barragens.

A forma observada da distribuição (como seu grau de assimetria ou espessura das caudas) depende fortemente das condições físicas do fenômeno, da resolução do procedimento de medição e da escala de agregação temporal ou espacial. É crucial destacar, para fins didáticos, que a mera semelhança visual entre um histograma empírico e a curva de densidade de um modelo teórico não prova a existência de um mecanismo físico gerador subjacente. Um histograma bimodal de temperaturas coletadas ao longo de um ano, por exemplo, não revela uma nova lei termodinâmica, mas frequentemente resulta da combinação de duas populações sazonais distintas (verão e inverno) com médias diferentes. A estatística descreve o padrão, mas a justificativa do modelo exige compreensão física.

3.2 Exemplos de relações entre grandezas e famílias de distribuições

Diferentes mecanismos físicos e teoremas probabilísticos dão origem a famílias clássicas de distribuições, cada qual com suas hipóteses fundamentais e limites de validade. A Tabela 3 resume as motivações teóricas para a adoção de alguns modelos de referência habituais.

Tabela 3: Relação entre fenômenos físicos, modelos estatísticos e suas premissas.

Grandeza ou situação	Modelo	Hipóteses ou limites físicos a explicar
Soma de múltiplas contribuições independentes	Normal (gaussiana)	O teorema central do limite exige condições (variância finita, independência). Não garante, por exemplo, que toda série temporal de temperatura seja normal.
Módulo de duas componentes ortogonais gaussianas	Rayleigh	Assume componentes independentes, de média nula e mesma variância; sua aplicação ao vento atmosférico real requer verificação.
Máximos por blocos (cheias anuais, rajadas)	Gumbel (valores extremos)	A família limite depende da forma da distribuição de origem. Nem todo valor máximo converge para um modelo de Gumbel.
Resistência de materiais ou tempo até a falha	Weibull	A adequação depende da microestrutura do material, do modo de propagação da falha e das condições do ensaio.

A distribuição de Rayleigh ilustra como uma hipótese cinemática gera um modelo estatístico. Considere-se a velocidade horizontal do vento, com componentes ortogonais V_x e V_y , e assumamos que ambas são variáveis aleatórias independentes e normalmente distribuídas, com médias nulas e variâncias idênticas σ^2 . A densidade conjunta é o produto

das densidades marginais,

$$f_{V_x, V_y}(v_x, v_y) = \frac{1}{2\pi\sigma^2} \exp\left(-\frac{v_x^2 + v_y^2}{2\sigma^2}\right). \quad (11)$$

A grandeza física de interesse usualmente é o módulo da velocidade, $v = \sqrt{v_x^2 + v_y^2}$. Transformando para coordenadas polares, em que o elemento de área $dv_x dv_y$ se torna $v dv d\theta$, e integrando o ângulo θ de 0 a 2π , obtém-se a densidade da distribuição de Rayleigh,

$$f_V(v) = \frac{v}{\sigma^2} \exp\left(-\frac{v^2}{2\sigma^2}\right), \quad v \geq 0. \quad (12)$$

Nesta formulação, o parâmetro de escala σ tem interpretação direta, pois, como $E[V^2] = E[V_x^2] + E[V_y^2] = 2\sigma^2$, a quantidade σ^2 é a energia cinética média por unidade de massa associada ao movimento horizontal. Cabe ressaltar que a atmosfera real está sujeita a efeitos de rugosidade do terreno e gradientes térmicos, de modo que as hipóteses da dedução não devem ser tomadas como válidas para o vento atmosférico sem a devida verificação empírica.

3.3 Por que isso importa na confiabilidade de materiais?

Compreender o comportamento distributivo transcende o mero ajuste de curvas; é o fundamento da teoria de confiabilidade estrutural e de materiais. Suponha-se que uma estrutura, como uma viga de concreto armado, possua uma resistência mecânica de comportamento aleatório, modelada pela variável R . Se esta estrutura é submetida a uma solicitação (carga) fixa conhecida s , a falha ocorrerá sempre que a resistência for inferior à solicitação.

Neste cenário simplificado, a probabilidade de falha P_f é exatamente o valor da função distribuição acumulada (FDA) de R avaliada no ponto s ,

$$P_f = P(R < s) = F_R(s). \quad (13)$$

Esse simples balanço mostra por que conhecer apenas a resistência média de um material é insuficiente para a engenharia. A segurança da estrutura é governada pelo comportamento da *cauda inferior* da distribuição (os valores mais baixos e raros de resistência), e um modelo cuja cauda inferior não corresponda à dos dados pode subestimar a probabilidade de falha. Em projetos reais, tanto R quanto s são grandezas aleatórias, exigindo a avaliação da interferência probabilística entre ambas e evidenciando a necessidade de escolhas de distribuições que reflitam a física da falha, conforme discutido em diretrizes de referência sobre dados de falha (NIST/SEMATECH, 2012).

3.4 Protocolo comum aos estudos de caso

Para garantir reprodutibilidade, rigor estatístico e clareza didática na análise dos dados, os estudos de caso desenvolvidos nas Seções 4 e 5 seguem um protocolo dividido nas sete etapas sequenciais descritas a seguir.

1. **Documentação dos dados e contextualização física:** identificação da fonte primária (instituição, estação de monitoramento, coordenadas e altitude), período de observação, grandeza física medida, resolução temporal das leituras (por exemplo, médias diárias ou valores instantâneos) e instrumental associado.
2. **Exame de qualidade e consistência física:** levantamento de dados ausentes, identificação de eventuais leituras espúrias e avaliação de restrições de suporte (por exemplo, a não negatividade da velocidade do vento ou os limites da umidade relativa). Os critérios de descarte ou tratamento de falhas são explicitados e fundamentados.
3. **Definição do recorte amostral:** estabelecimento prévio e justificado de janelas temporais ou espaciais homogêneas (como o recorte de um mês específico para atenuar a não estacionariedade sazonal), evitando seleções *a posteriori* direcionadas a favorecer um modelo pré-determinado.
4. **Descrição estatística exploratória:** caracterização da amostra por medidas de posição, dispersão, assimetria ($\hat{\gamma}_1$) e curtose ($\hat{\beta}_2$), acompanhadas de quantis empíricos de referência ($Q_{0,05}$, $Q_{0,50}$, $Q_{0,95}$) e de gráficos da série temporal e do histograma.
5. **Estimação de parâmetros e ajuste das famílias:** ajuste dos modelos de referência, estimados por máxima verossimilhança com as restrições físicas de suporte (como a origem fixada em zero), e da GLD-FKML, estimada pelo método dos momentos com múltiplos pontos iniciais. A validade dos parâmetros e o suporte resultante são verificados.
6. **Diagnóstico de aderência e comparação quantílica:** avaliação comparativa por métricas nas unidades da grandeza. Utiliza-se a distância de Kolmogorov-Smirnov, $D_n = \sup_x |F_n(x) - \hat{F}(x)|$, para medir a maior discrepância acumulada, e os desvios quantílicos

$$\Delta_p = Q_{\text{modelo}}(p) - Q_{\text{empírico}}(p), \quad p \in \{0,05; 0,50; 0,95\}, \quad (14)$$

cujo sinal indica subestimação (negativo) ou superestimação (positivo). Os ajustes são comparados visualmente em painéis com densidades sobrepostas, funções acumuladas e gráficos quantil-quantil (Q-Q).

7. **Interpretação nas unidades do fenômeno e limites de validade:** tradução física das discrepâncias para o contexto da aplicação, comparando-as com a incerteza

de medição e discutindo o princípio da parcimônia frente ao custo de parâmetros adicionais.

A distância D_n é usada aqui como medida descritiva. Os p-valores usuais do teste de Kolmogorov-Smirnov não se aplicam diretamente, porque os parâmetros são estimados com os mesmos dados, as observações diárias são dependentes entre si e os valores registrados são arredondados.

4. Ajuste de distribuições e interpretação de dados de vento

4.1 Apresentação breve da biblioteca e do ambiente

Para a condução deste estudo de caso e a reprodução dos ajustes propostos, emprega-se a biblioteca `pyglam` (versão 1.1.0) (Pereira Junior et al., 2026), desenvolvida em Python e disponibilizada publicamente, e as distribuições clássicas da biblioteca `scipy.stats` (Virtanen et al., 2020). O pacote implementa a parametrização FKML da família lambda generalizada e o seu ajuste pelo método dos momentos, descrito na Seção 2.

O fluxo de trabalho computacional apoia-se em funções fundamentais da biblioteca, sendo `GlamFKML` usada para a instanciação do modelo paramétrico, `fit_lambdas` para a execução do algoritmo de ajuste e os métodos `pdf` (função densidade de probabilidade), `cdf` (função distribuição acumulada) e `ppf` (função quantil, do inglês *percent point function*). Adicionalmente, o método `rvs` permite a geração de amostras aleatórias via transformação inversa. Cabe ressaltar uma característica do desenho da biblioteca. A função de ajuste retorna a solução do otimizador (`sol.x`), e o usuário instancia explicitamente o modelo ajustado (`modelo = GlamFKML(*sol.x)`), em vez de alterar a instância original.

4.2 Origem, unidade e qualidade dos dados

Os dados empíricos utilizados neste estudo são as velocidades médias diárias do vento (em m/s) da estação meteorológica automática A001, em Brasília (DF), do Instituto Nacional de Meteorologia (Instituto Nacional de Meteorologia – INMET, 2025). O arquivo compreende o período de 06/05/2000 a 25/04/2025, com 9.121 registros diários sem datas repetidas; destes, 8.840 contêm a velocidade do vento e 281 estão vazios. Não há registros nulos ou negativos, e os valores têm resolução de 0,1 m/s.

As velocidades diárias válidas variam entre o mínimo de 0,7 m/s e o máximo de 5,5 m/s, com média amostral de 2,345 m/s e desvio padrão de 0,711 m/s (calculado com divisor n).

4.3 Caracterização exploratória

Antes da imposição de qualquer modelo probabilístico, a estatística descritiva e a visualização exploratória fornecem o comportamento de base da grandeza física. A velocidade média diária do vento apresenta assimetria positiva, limitando-se inferiormente pelo zero físico e estendendo-se em uma cauda direita que acomoda dias excepcionalmente ventosos.

A Figura 2 mostra a série temporal e o histograma, evidenciando a concentração da massa de probabilidade na faixa de 1,5 a 3,0 m/s. A Tabela 4 sintetiza as estatísticas descritivas dos dois estudos de caso, incluindo os quantis de 5%, 50% e 95%, que servirão de referência numérica para avaliar as curvas ajustadas.




Figura 2: Velocidade média diária do vento na estação automática A001, em Brasília (DF), com (a) a série temporal e a média móvel de 30 dias e (b) o histograma.

4.4 Famílias comparadas e estimação

O ajuste estatístico compara três modelos paramétricos, a GLD-FKML (quatro parâmetros, estimada pelo método dos momentos) e dois modelos clássicos de referência com origem fixada no zero físico, a distribuição de Rayleigh (um parâmetro) e a distribuição de Weibull (dois parâmetros), ambas ajustadas por máxima verossimilhança.

A adoção da distribuição de Rayleigh no escopo atmosférico assume as hipóteses da Seção 3 (componentes de vento gaussianas, ortogonais e independentes). O estimador de máxima verossimilhança para esta família é $\hat{\sigma} = \sqrt{\sum_{i=1}^n v_i^2 / (2n)}$, que fornece $\hat{\sigma} = 1,733$ m/s.

Tabela 4: Estatísticas descritivas dos dois estudos de caso. Desvio padrão com divisor n e curtose de Pearson (igual a 3 para a normal).

Estatística	Vento (m/s)	Temperatura em julho (°C)
n	8.840	768
Média	2,345	19,409
Mediana	2,20	19,50
Desvio padrão	0,711	1,466
Coefficiente de variação	0,303	0,076
Assimetria	0,738	-0,482
Curtose (Pearson)	3,368	3,717
Mínimo; máximo	0,7; 5,5	14,0; 23,2
$Q_{0,05}$; $Q_{0,50}$; $Q_{0,95}$	1,40; 2,20; 3,70	16,84; 19,50; 21,70

No entanto, uma limitação estrutural surge imediatamente dos dados, pois o coeficiente de variação (CV) da distribuição de Rayleigh com origem em zero é uma constante, $\sqrt{(4 - \pi)/\pi} \approx 0,523$, independentemente de σ . Em contrapartida, o CV empírico da amostra diária analisada é de 0,303. Esta discrepância impede que o modelo de Rayleigh se adapte à forma da distribuição dos dados observados, qualquer que seja sua escala.

A introdução do modelo de Weibull flexibiliza essa restrição ao incorporar um parâmetro de forma (sendo a Rayleigh seu caso particular quando esse parâmetro vale 2). O ajuste fornece forma $\hat{k} = 3,448$ e escala $\hat{c} = 2,605$ m/s, o que oferece uma base de comparação mais justa com a flexibilidade dos quatro parâmetros da GLD-FKML.

Para a GLD-FKML, o sistema de equações não lineares do ajuste por momentos é sensível à aproximação inicial. O algoritmo explora por isso 15 pontos de partida e seleciona, entre os candidatos que definem uma distribuição válida, a solução de menor resíduo (Seção 2). Os quinze candidatos foram válidos, e a solução obtida, $\hat{\lambda} = (2,191; 1,727; 0,556; 0,099)$, reproduz os quatro momentos da amostra. Como λ_3 e λ_4 são positivos, a Equação (6) indica que o modelo ajustado tem suporte limitado, de 1,148 a 8,057 m/s; a consequência desse resultado é discutida na Seção 4.6.

O Código ??, que continua o Código ??, executa esse ajuste, calcula os limites do suporte pela Equação (6) e conta as observações que ficam fora dele.

4.5 O que medir e como ensinar a leitura do desempenho

A avaliação de modelos não deve se encerrar em métricas opacas, mas traduzir a precisão na unidade física do problema. O diagnóstico deste estudo concentra-se em dois aspectos.

1. **Aderência global:** distância de Kolmogorov-Smirnov, $D_n = \sup_v |F_n(v) - \hat{F}(v)|$, que quantifica o maior desvio absoluto entre a acumulada empírica e a do modelo.
2. **Desvios nas caudas e no centro:** diferenças quantílicas Δ_p da Equação (14), nos percentis $p \in \{0,05; 0,50; 0,95\}$. O sinal de Δ_p indica imediatamente se o modelo subestima (negativo) ou superestima (positivo) o vento, em m/s.

Código 2: Ajuste da GLD-FKML aos dados de vento pelo método dos momentos e verificação do suporte.

```

1 import pandas as pd
2
3 dados = pd.read_csv("estacao_A001_diario.csv")
4 v = dados["vento_ms"].dropna().to_numpy()      # velocidades médias diárias (m/s)
5
6 # método dos momentos a partir de 15 pontos iniciais
7 sol = GlamFKML().fit_lambdas(v, n_starts=15, seed=0)
8 gld = GlamFKML(*sol.x)                        # modelo ajustado
9 l1, l2, l3, l4 = sol.x
10
11 # limites do suporte, como na equação do suporte
12 a = l1 - 1 / (l2 * l3) if l3 > 0 else -np.inf
13 b = l1 + 1 / (l2 * l4) if l4 > 0 else np.inf
14 fora = np.sum((v < a) | (v > b))              # observações fora do suporte

```

O Código ?? calcula as duas métricas para a GLD ajustada no Código ?. Para os modelos de Rayleigh e de Weibull, basta trocar gld pela distribuição correspondente da biblioteca `scipy.stats`, que oferece os mesmos métodos `ppf` e `cdf`.

Código 3: Desvios quantílicos e distância de Kolmogorov-Smirnov do modelo ajustado.

```

1 # desvios quantílicos, em m/s
2 p = np.array([0.05, 0.50, 0.95])
3 delta = gld.ppf(p) - np.quantile(v, p)
4
5 # distância de Kolmogorov-Smirnov entre a acumulada empírica e a do modelo
6 x = np.sort(v)
7 n = x.size
8 F = gld.cdf(x)
9 i = np.arange(1, n + 1)
10 Dn = max(np.max(i / n - F), np.max(F - (i - 1) / n))

```

A Tabela 5 compila estas métricas. A Figura 3 reúne a densidade, a função acumulada e o gráfico Q-Q, permitindo localizar em quais quantis cada modelo se afasta dos dados.

Tabela 5: Desempenho dos modelos ajustados aos dados diários de vento. As diferenças de quantis Δ_p estão em m/s.

Modelo	Parâmetros	D_n	$\Delta_{0,05}$	$\Delta_{0,50}$	$\Delta_{0,95}$
Rayleigh	1	0,242	-0,845	-0,159	+0,542
Weibull	2	0,085	-0,299	+0,142	-0,119
GLD-FKML	4	0,041	-0,025	+0,046	-0,037

4.6 Interpretação física e didática

A leitura dos resultados revela que o coeficiente de variação fixo da distribuição de Rayleigh a torna larga demais para estes dados. Ela subestima o quantil de 5% em 0,845 m/s




Figura 3: Diagnóstico comparativo dos modelos ajustados ao vento, com (a) densidades sobrepostas ao histograma, (b) funções distribuição acumuladas e (c) gráfico quantil-quantil, em que a linha pontilhada indica concordância perfeita.

e a mediana em 0,159 m/s, e superestima o quantil de 95% em 0,542 m/s, sendo inadequada para descrever o regime diário neste sítio. O modelo de Weibull melhora bastante a aderência, mas ainda erra o quantil de 5% em 0,299 m/s e a mediana em 0,142 m/s.

A GLD-FKML, que reproduz a assimetria e a curtose da amostra, reduz a distância D_n à metade da obtida com a Weibull e mantém os três desvios quantílicos abaixo de 0,05 m/s, inferiores à resolução de 0,1 m/s dos dados. Contudo, do ponto de vista didático, é imprescindível examinar o suporte do modelo ajustado. O limite inferior de 1,148 m/s é positivo, o que evita atribuir probabilidade a velocidades negativas, mas está acima do menor valor observado, e 84 dias da amostra (0,95%) registraram velocidades menores, às quais o modelo atribui probabilidade nula. O ajuste por momentos reproduz os quatro resumos da amostra, mas nada no método obriga o suporte a conter todas as observações. A lição central do exemplo é que a qualidade global do ajuste não dispensa a verificação da cauda relevante para a aplicação.

Por fim, os dados analisados são médias diárias. Eles descrevem a variabilidade de um dia para outro, mas não permitem recuperar a distribuição das velocidades instantâneas, que é a relevante para estimar a potência eólica, proporcional ao cubo da velocidade. Estender a análise a esse fim exigiria dados de maior resolução temporal.

5. Ajuste e interpretação de dados de temperatura

5.1 Por que esta grandeza?

A temperatura do ar é uma das grandezas termodinâmicas mais familiares no cotidiano e na experimentação científica elementar.

Frequentemente, em cursos introdutórios de física e engenharia, assume-se como premissa tácita que grandezas contínuas se comportam de forma gaussiana. Contudo, a

grandeza física “temperatura” não determina, por si só, uma distribuição normal. A série agregada ao longo de vários anos incorpora fortes efeitos sazonais e transições de massas de ar que geram a sobreposição de populações com médias e variâncias distintas.

Este segundo exemplo desempenha um papel pedagógico complementar ao estudo da velocidade do vento. Enquanto no vento investigou-se a restrição de suporte e a assimetria positiva, na temperatura examina-se até que ponto uma distribuição aproximadamente simétrica justifica o abandono da distribuição normal em favor de uma família flexível de quatro parâmetros, ensinando o estudante a formular e testar criticamente essa hipótese.

5.2 Definição do recorte temporal

A análise da série plurianual completa revela uma variação sazonal evidente, que inviabiliza um modelo único para todo o ano sem estratificação. Para manter um recorte físico e temporal mais homogêneo, selecionou-se a temperatura média diária do mês de julho. O recorte contempla 768 observações diárias válidas, distribuídas ao longo de 25 invernos (2000 a 2024).

A escolha de julho foi estabelecida *a priori*, com base em um critério climatológico (o auge do inverno no Centro-Oeste brasileiro), e não por meio de uma varredura exploratória em busca do mês com maior aderência à normal ou à GLD. A restrição ao calendário atenua a heterogeneidade entre estações do ano, embora não elimine a dependência entre dias adjacentes nem a variabilidade interanual. O modelo ajustado deve ser interpretado como a caracterização probabilística das temperaturas médias diárias observadas em julho naquela estação meteorológica.

A Figura 4 ilustra o ciclo anual da temperatura na estação por meio da distribuição mensal e destaca a série do mês de julho.

5.3 Ajustes, gráficos e métricas

A amostra de julho (Tabela 4) apresenta temperatura média de 19,409 °C, desvio padrão de 1,466 °C (com divisor n), assimetria moderadamente negativa ($-0,482$) e curtose de Pearson de 3,717, isto é, um excesso de 0,717 em relação à normal. Os quantis empíricos de 5%, 50% e 95% são 16,84 °C, 19,50 °C e 21,70 °C, respectivamente.

Aplicando o mesmo protocolo da Seção 4, comparou-se o modelo normal, com parâmetros de máxima verossimilhança $\hat{\mu} = 19,409^\circ\text{C}$ e $\hat{\sigma} = 1,466^\circ\text{C}$, com a GLD-FKML ajustada pelo método dos momentos com a biblioteca `pyglam`, que resultou em $\hat{\lambda} = (19,538; 1,071; 0,018; 0,184)$.

As discrepâncias quantílicas são reportadas diretamente na unidade física (Δ_p , em °C). A Tabela 6 apresenta os diagnósticos comparativos e a Figura 5 sintetiza a sobreposição das densidades, as funções acumuladas e o gráfico Q-Q.




Figura 4: Temperatura média diária na estação A001, com (a) a distribuição por mês, destacando julho, e (b) a série das temperaturas de julho, de 2000 a 2024.

Tabela 6: Desempenho dos modelos ajustados às temperaturas médias diárias de julho. As diferenças de quantis Δ_p estão em °C.

Modelo	Parâmetros	D_n	$\Delta_{0,05}$	$\Delta_{0,50}$	$\Delta_{0,95}$
Normal	2	0,064	+0,163	-0,091	+0,120
GLD-FKML	4	0,041	+0,025	+0,002	-0,058




Figura 5: Diagnóstico comparativo das temperaturas de julho, com (a) densidades sobrepostas ao histograma, (b) funções distribuição acumuladas e (c) gráfico quantil-quantil, em que a linha pontilhada indica concordância perfeita.

5.4 Interpretação didática e física

A análise dos resultados conduz a uma reflexão conceitual sobre o princípio da parcimônia (navalha de Ockham) no tratamento de dados físicos. A distribuição normal ajustada exibe uma distância de Kolmogorov-Smirnov pequena ($D_n = 0,064$), e os desvios quantílicos situam-se na ordem de décimos de grau Celsius ($+0,16^\circ\text{C}$ no quantil de 5% e $+0,12^\circ\text{C}$ no de 95%).

Na prática instrumental de estações automáticas de superfície, a incerteza de medição da temperatura do ar é da ordem de alguns décimos de grau Celsius, de modo que as discrepâncias do modelo normal são da mesma ordem de grandeza da incerteza experimental. Nesses casos, mesmo que a GLD-FKML acomode a assimetria negativa e reduza D_n para 0,041, com desvios quantílicos abaixo de $0,06^\circ\text{C}$, o acréscimo de dois parâmetros livres exige julgamento crítico, pois, para muitas aplicações térmicas usuais, o modelo normal de dois parâmetros oferece uma descrição simples, robusta e aceitável.

O suporte da GLD ajustada reforça essa leitura. Com λ_3 e λ_4 positivos, o modelo é limitado nos dois lados, entre $-33,9^\circ\text{C}$ e $24,6^\circ\text{C}$. O limite superior é plausível, pouco acima do máximo observado de $23,2^\circ\text{C}$; o inferior é fisicamente implausível para Brasília em julho, embora o modelo atribua a essa região uma probabilidade desprezível, porque λ_3 muito pequeno produz uma cauda esquerda longa e extremamente fina. Os limites do suporte, portanto, são uma consequência matemática dos parâmetros, e não devem ser lidos como limites físicos da grandeza.

Por outro lado, caso o foco resida na estimativa de eventos de frio intenso (cauda esquerda), a assimetria negativa capturada pela GLD ganha relevância. É imperativo frisar aos estudantes que os quantis estimados descrevem a variabilidade das temperaturas médias diárias no histórico observado do mês; não representam intervalos de confiança da média amostral, nem limites do sensor, tampouco uma previsão para um dia específico.

5.5 Por que não a precipitação?

A justificativa pedagógica para a escolha da temperatura em detrimento de grandezas como a precipitação evidencia cuidados indispensáveis na modelagem empírica, discutidos a seguir.

1. **Precipitação diária:** na série histórica, de 8.759 valores válidos, 5.675 são exatamente iguais a zero (dias sem chuva). Variáveis com massa de probabilidade concentrada na origem não podem ser representadas diretamente por uma única densidade contínua; exigiriam um modelo misto (uma parte para a ocorrência de chuva e uma densidade contínua para os dias chuvosos), introduzindo uma complexidade alheia ao objetivo didático central do artigo.
2. **Máximos anuais de chuva e o modelo de Gumbel:** a teoria de valores extremos frequentemente associa máximos em blocos à distribuição de Gumbel. Todavia,

a série da estação automática conta com apenas 24 máximas anuais. Ajustar quatro momentos de uma distribuição flexível sobre $n = 24$ resulta em estimadores de variância elevada. Além disso, a presença de dias ausentes em cada ano (com cobertura entre 300 e 366 dias) introduz uma incerteza importante, pois o dia faltante pode ser precisamente o da máxima anual.

Assim, a temperatura média diária no recorte de julho constitui um exemplo didático adequado, com dados contínuos, amostra expressiva ($n = 768$) e simetria aproximada suficiente para contrastar a virtude da simplicidade analítica com o custo da flexibilidade paramétrica.

6. Considerações finais

Este artigo apresentou um percurso didático para a modelagem probabilística de dados físicos reais com a distribuição lambda generalizada, na parametrização FKML, ajustada pelo método dos momentos e comparada com distribuições clássicas pertinentes a cada grandeza.

Os dois exemplos levaram a conclusões diferentes, e essa diferença é o seu valor didático. Para a velocidade média diária do vento, a flexibilidade da GLD fez diferença. A distribuição de Rayleigh, com coeficiente de variação fixo, não descreve os dados; a de Weibull melhora bastante o ajuste; e a GLD reduz os desvios nos quantis de interesse a menos da resolução das medições. O mesmo exemplo, porém, mostrou que reproduzir os quatro momentos da amostra não garante um suporte compatível com as observações, pois o modelo ajustado exclui os dias de vento mais fraco. Para a temperatura de julho, a GLD também se aproxima mais dos dados, mas as discrepâncias da normal são da ordem da incerteza de medição, e o modelo de dois parâmetros permanece uma escolha defensável. As conclusões valem para as variáveis, os recortes e o método de estimação analisados.

A formulação por quantis mostrou-se vantajosa em três aspectos. Os percentis são obtidos diretamente e lidos nas unidades da grandeza, o que torna a comparação entre modelos interpretável em m/s ou em °C. A amostragem por transformação inversa é imediata. E os parâmetros têm efeitos visualizáveis sobre a forma da distribuição. Em contrapartida, a densidade e a função acumulada exigem procedimentos numéricos, e o ajuste por momentos requer verificar a validade, o domínio dos momentos, o suporte e a aderência de cada solução.

O material aborda dificuldades conceituais recorrentes no ensino, como distinguir densidade e probabilidade, interpretar quantis, compreender momentos de ordem alta, reconhecer que a convergência numérica não garante aderência, separar a adequação estatística da explicação física e perceber os efeitos do recorte e da agregação temporal. Por não ter sido aplicado em sala de aula, o material não permite afirmar ganhos de aprendizagem, o que fica como passo seguinte.

Os Códigos ?? a ?? mostram o essencial do procedimento. O notebook didático completo, que reproduz todas as figuras e tabelas deste artigo com explicações entre as etapas, os trechos de código e os dados acompanham o artigo para download, com as instruções de execução. A biblioteca `pyglam` está disponível em <https://github.com/Pesquisa-UFCAT/pyGLAM> e pode ser instalada com `pip install pyglam`.

Agradecimentos

Renata Maria Pensin agradece ao Conselho Nacional de Desenvolvimento Científico e Tecnológico (CNPq) pela bolsa de iniciação científica. Victor Hugo Moreira do Couto Souza agradece à Fundação de Amparo à Pesquisa do Estado de Goiás (FAPEG) pela bolsa de mestrado.

Disponibilidade dos dados

Os dados meteorológicos utilizados são públicos e foram obtidos do Banco de Dados Meteorológicos do Instituto Nacional de Meteorologia (Instituto Nacional de Meteorologia – INMET, 2025). O arquivo utilizado e o notebook que reproduz todas as figuras e tabelas deste artigo acompanham o manuscrito como material suplementar.

Conflito de interesses

Os autores declaram não haver conflito de interesses.

Referências

- Freimer, M., Kollia, G., Mudholkar, G. S., & Lin, C. T. (1988). A Study of the Generalized Tukey Lambda Family. *Communications in Statistics - Theory and Methods*, 17(10), 3547–3567. <https://doi.org/10.1080/03610928808829820>
- Giannoukou, K., Zhu, X.-J., Marelli, S., & Sudret, B. (2025). MF-GLaM: A Multifidelity Stochastic Emulator Using Generalized Lambda Models [Disponível via arXiv:2507.10303 [stat.ML]]. *Computer Methods in Applied Mechanics and Engineering*. <https://doi.org/10.48550/arXiv.2507.10303>
- Hastings, C., Mosteller, F., Tukey, J. W., & Winsor, C. P. (1947). Low Moments for Small Samples: A Comparative Study of Order Statistics. *The Annals of Mathematical Statistics*, 18(3), 413–426. <https://doi.org/10.1214/aoms/1177730388>
- Instituto Nacional de Meteorologia – INMET. (2025). Banco de Dados Meteorológicos para Ensino e Pesquisa (BDMEP): Estação Automática A001 [Série histórica diária (2000–2025)].

- Johnson, N. L. (1949). Systems of Frequency Curves Generated by Methods of Translation. *Biometrika*, 36(1-2), 149–176. <https://doi.org/10.1093/biomet/36.1-2.149>
- King, R., Dean, B., Klinke, S., & van Staden, P. (2025). *gld: Estimation and Use of the Generalised (Tukey) Lambda Distribution* [R package version 2.6.8]. <https://CRAN.R-project.org/package=gld>
- NIST/SEMATECH. (2012). e-Handbook of Statistical Methods: Choice of Distribution for Life/Failure Data [Acessado em: 25 set. 2026].
- Pearson, K. (1895). Contributions to the Mathematical Theory of Evolution. II. Skew Variation in Homogeneous Material. *Philosophical Transactions of the Royal Society of London. A*, 186, 343–414. <https://doi.org/10.1098/rsta.1895.0010>
- Pereira Junior, W. M., Henrique, M. L., dos Santos, K. R. M., Souza, V. H. M. d. C., & Pensin, R. M. (2026). *pyGLAM: Generalized Lambda Distribution Models in Python* [Pacote Python, versão 1.1.0]. <https://github.com/Pesquisa-UFCAT/pyGLAM>
- Ramberg, J. S., & Schmeiser, B. W. (1974). An Approximate Method for Generating Asymmetric Random Variables. *Communications of the ACM*, 17(2), 78–82. <https://doi.org/10.1145/360827.360840>
- Tukey, J. W. (1960). *The Practical Relationship between the Common Transformations of Percentages of Counts and of Amounts* (Technical Report N. 36). Statistical Techniques Research Group, Princeton University.
- Virtanen, P., Gommers, R., Oliphant, T. E., Haberland, M., Reddy, T., Cournapeau, D., Burovski, E., Peterson, P., Weckesser, W., Bright, J., van der Walt, S. J., Brett, M., Wilson, J., Millman, K. J., Mayorov, N., Nelson, A. R. J., Jones, E., Kern, R., Larson, E., ... SciPy 1.0 Contributors. (2020). SciPy 1.0: Fundamental Algorithms for Scientific Computing in Python. *Nature Methods*, 17, 261–272. <https://doi.org/10.1038/s41592-019-0686-2>
- Zhu, X.-J., & Sudret, B. (2021). Emulation of Stochastic Simulators Using Generalized Lambda Models. *SIAM/ASA Journal on Uncertainty Quantification*, 9(4), 1345–1374. <https://doi.org/10.1137/20M1337302>